

Optimización de la producción de surfactina en la industria biotecnológica utilizando un diseño factorial 2^4 sin réplicas

Optimization of Surfactin Production in the Biotechnology Industry Using a 2^4 Factorial Design without Replication

Alvaro Alberto Ayesta Ramirez, Ibeth Sofia Dextre Simangas, Sebastian Matias Romero Davila, Frankli Zeña Zeña

alvaro.ayesta.r@uni.pe, ibeth.dextre.s@uni.pe, sebastian.romero.d@uni.pe,
frankli.zena.z@uni.pe

Resumen

Este estudio implementó un diseño factorial completo 2^4 con 16 corridas experimentales y 6 puntos centrales para optimizar la producción de surfactina mediante el control de cuatro componentes del medio de cultivo: glucosa, NH_4NO_3 , FeSO_4 y MnSO_4 . La concentración de surfactina se cuantificó mediante mediciones de tensión superficial, expresándose como el inverso de la concentración micelar crítica $(CMC)^{-1}$. El análisis mediante diagrama de Pareto identificó los efectos significativos, seguido de ANOVA que reveló que FeSO_4 y MnSO_4 fueron los factores más influyentes, junto con la interacción Glucosa $\times\text{NH}_4\text{NO}_3$. La inclusión de puntos centrales detectó curvatura significativa y mejoró sustancialmente las métricas del modelo, alcanzando R^2 ajustado = 97,54 % y R^2 de predicción = 93,42 %. Las condiciones óptimas identificadas fueron: glucosa 20 g/dm³, NH_4NO_3 2 g/dm³, FeSO_4 30×10^{-4} g/dm³ y MnSO_4 20×10^{-2} g/dm³. Se concluye que si bien el modelo lineal con interacciones es adecuado para la optimización dentro del rango experimental estudiado, la curvatura detectada mediante los puntos centrales sugiere que un modelo polinomial de segundo orden representaría más adecuadamente el comportamiento real del sistema.

Index Terms: Optimización de medios, glucosa, nitrato de amonio, sulfato de hierro, sulfato de manganeso, surfactina, diseño factorial, *Bacillus subtilis*, Análisis de varianza.

Abstract

This study implemented a complete 2^4 factorial design with 16 experimental runs and 6 center points to optimize surfactin production by controlling four culture medium components: glucose, NH_4NO_3 , FeSO_4 , and MnSO_4 . Surfactin concentration was quantified through surface tension measurements, expressed as the inverse of the critical micellar concentration $(CMC)^{-1}$. Pareto analysis identified significant effects, followed by ANOVA which revealed that FeSO_4 and MnSO_4 were the most influential factors, along with the Glucose $\times\text{NH}_4\text{NO}_3$ interaction. The inclusion of center points detected significant curvature and substantially improved model metrics, achieving adjusted R^2 = 97,54 % and predicted R^2 = 93,42 %. The optimal conditions identified were: glucose 20 g/dm³, NH_4NO_3 2 g/dm³, FeSO_4 30×10^{-4} g/dm³, and MnSO_4 20×10^{-2} g/dm³. It is concluded that while the linear model with interactions is adequate for optimization within the studied experimental range, the curvature detected through center points suggests that a second-

order polynomial model more adequately represents the real system behavior.

Index Terms: Optimización de medios, glucosa, nitrato de amonio, sulfato de hierro, sulfato de manganeso, surfactina, diseño factorial, *Bacillus subtilis*, Análisis de varianza.

1. INTRODUCCIÓN

La surfactina es un biosurfactante de gran interés industrial debido a sus propiedades tensioactivas, antimicrobianas y antivirales, producido principalmente por cepas de *Bacillus subtilis*. Sin embargo, su producción a escala industrial se ve limitada por la baja eficiencia de los medios de cultivo y la falta de optimización sistemática de los componentes críticos que afectan su síntesis [1]. Estudios previos han identificado que fuentes de carbono, nitrógeno y micronutrientes como hierro y manganeso influyen significativamente en la biosíntesis de surfactina [2].

En procesos biotecnológicos, la variabilidad no controlada en la composición del medio puede enmascarar el efecto real de los factores de interés, reduciendo la capacidad de detectar diferencias significativas entre tratamientos [3]. El diseño factorial completo permite cuantificar los efectos principales y las interacciones entre múltiples factores con un número eficiente de experimentos, mejorando la precisión en la identificación de condiciones óptimas [4].

En este contexto, se utilizaron datos reportados en el *Journal of Chemical Technology and Biotechnology* (1997), correspondientes a un diseño factorial 2^4 con 16 corridas experimentales, para evaluar el efecto de cuatro componentes del medio en la producción de surfactina.

1.1. Formulación del problema

Existe incertidumbre sobre si los componentes glucosa, NH_4NO_3 , FeSO_4 y MnSO_4 , así como sus interacciones, afectan significativamente la producción de surfactina medida como $(CMC)^{-1}$, cuando se evalúan bajo un diseño factorial completo 2^4 .

En este marco, la pregunta de investigación es: ¿Existen efectos significativos de los componentes químicos y sus interacciones sobre la producción de surfactina?

Hipótesis:

- H_0 : No hay efectos significativos de glucosa, NH_4NO_3 , FeSO_4 , MnSO_4 ni sus interacciones sobre $(\text{CMC})^{-1}$.
- H_1 : Al menos un factor o interacción tiene un efecto significativo.

1.2. Objetivo General

Determinar la combinación óptima de los niveles de glucosa, nitrato de amonio, sulfato de hierro y sulfato de manganeso que maximice la producción de surfactina, representada por el valor de la concentración micelar crítica $(\text{CMC})^{-1}$.

1.3. Objetivos Específicos

1. Determinar si existen efectos principales e interacciones significativas que influyen en la producción de surfactina.
2. Cuantificar la contribución porcentual de cada factor a la variabilidad total.
3. Establecer recomendaciones basadas en evidencia para la optimización de producción de surfactina.
4. Determinar si la inclusión de puntos centrales en el modelo generan curvatura.

2. MARCO TEÓRICO

2.1. Surfactina

La surfactina es una molécula producida por la bacteria *Bacillus subtilis*, reconocida como uno de los biosurfactantes más eficientes. Está compuesta por una parte proteica (péptido) y una parte grasa (ácido graso), lo que le permite reducir notablemente la tensión superficial del agua.

Entre sus aplicaciones industriales destacan su uso en la industria farmacéutica como agente antimicrobiano, en alimentos como emulsionante, en cosmética por su biocompatibilidad, y en biorremediación para la degradación de hidrocarburos.

2.2. Componentes Críticos Típicos del Medio de Cultivo

La producción de surfactina depende críticamente de la composición del medio de cultivo. La **glucosa** constituye la principal fuente de carbono y energía, así como precursora del acetil-CoA necesario para la síntesis del ácido graso de la surfactina.

El **nitrato de amonio** (NH_4NO_3) proporciona nitrógeno asimilable para la síntesis de aminoácidos del heptapéptido. La relación carbono/nitrógeno es crítica para el balance metabólico durante la producción. El **sulfato de hierro** (FeSO_4) actúa como cofactor esencial en enzimas de la cadena respiratoria y en sistemas de transporte electrónico involucrados en la síntesis del surfactante. El **sulfato de manganeso** (MnSO_4) funciona como activador enzimático, particularmente en sistemas de defensa contra estrés oxidativo durante la producción del metabolito secundario.

Estos cuatro componentes trabajan en conjunto. Si alguno falta o está en cantidad incorrecta, la producción de surfactina disminuye notablemente.

2.3. Diseño Factorial 2^k

El diseño factorial 2^k es un tipo de diseño experimental utilizado para estudiar simultáneamente k factores, cada uno con dos niveles (alto y bajo). Su estructura considera todas las combinaciones posibles de los niveles de los factores, generando un total de 2^k tratamientos.

Este diseño permite estimar de manera eficiente los efectos principales de cada factor y las interacciones entre ellos sobre una variable de respuesta. Se emplea para identificar los factores que ejercen una influencia significativa en el comportamiento del sistema y optimizar los procesos experimentales. Asimismo, constituye la base para el desarrollo de diseños más complejos, como los factoriales fraccionados y los de superficie de respuesta. [2]

2.4. Supuestos

El análisis de un diseño factorial 2^k se basa en un modelo lineal aditivo que supone el cumplimiento de ciertas condiciones estadísticas. Estas garantizan que las estimaciones de los efectos sean insesgadas y que las inferencias obtenidas mediante el análisis de varianza (ANOVA) o la regresión lineal sean válidas. Los principales supuestos son los siguientes:

1. **Normalidad:** se asume que los errores experimentales (ε) se distribuyen normalmente con media cero. La verificación puede realizarse mediante pruebas estadísticas como Shapiro-Wilk o Kolmogorov-Smirnov, así como a través de representaciones gráficas como el histograma de residuos o el gráfico Q-Q. En caso de desviación de la normalidad, se recomienda aplicar una transformación de la variable de respuesta, como la logarítmica, raíz cuadrada o Box-Cox, para aproximar la distribución normal.
2. **Independencia:** se asume que los errores son independientes entre sí, es decir, que el valor de una observación no influye en otra. Este supuesto se evalúa analizando el orden de ejecución de los tratamientos y los residuos del modelo. En experimentos secuenciales puede emplearse la prueba de Durbin-Watson. Si se detecta dependencia, se debe realeatorizar el orden de las corridas experimentales o considerar un modelo que incorpore la correlación entre los errores.
3. **Homoscedasticidad (igualdad de varianzas):** este supuesto establece que la varianza de los errores es constante para todos los tratamientos. Se verifica mediante gráficos de residuos vs. valores ajustados, o con pruebas como Levene o Bartlett. Cuando el diseño factorial se analiza mediante su modelo de regresión lineal equivalente, también puede aplicarse la prueba de White, la cual detecta heterocedasticidad sin requerir una forma específica de la varianza. Si se identifica heterocedasticidad, pueden aplicarse transformaciones de la respuesta o utilizarse métodos robustos de estimación.
4. **Aditividad:** se supone que la respuesta puede expresarse como la suma de una media general, los efectos de los factores, sus interacciones y un término de error aleatorio, Ejem:

$$Y = \mu + A + B + AB + \varepsilon$$

Este supuesto se evalúa revisando los residuos del modelo y la significancia de las interacciones. Si se detecta curvatura o no aditividad, deben incorporarse términos cuadráticos o puntos centrales.

El cumplimiento de estos supuestos es esencial para asegurar la validez estadística del diseño factorial 2^k y la confiabilidad de las conclusiones obtenidas a partir del análisis experimental.

2.5. Modelo lineal del diseño 2^k

De manera general, el modelo para un diseño factorial con k factores se expresa como:

$$Y = \beta_0 + \sum_{i=1}^k \beta_i x_i + \sum_{i < j < l} \beta_{ijl} x_i x_j x_l + \dots + \beta_{12\dots k} x_1 x_2 \dots x_k + \varepsilon$$

donde:

- Y representa la variable de respuesta.
- β_0 es el término independiente o media general del sistema.
- β_i corresponde al efecto principal del factor i .
- $\beta_{ij}, \beta_{ijl}, \dots, \beta_{12\dots k}$ son los coeficientes que representan las interacciones de segundo, tercer y hasta k -ésimo orden entre los factores.
- x_i son las variables codificadas que representan los niveles de cada factor, tomando valores de -1 para el nivel bajo y $+1$ para el nivel alto.
- ε es el error experimental aleatorio, que se asume con media cero, varianza constante y distribución normal.

2.6. ANOVA

El análisis de varianza constituye la herramienta estadística fundamental para determinar si los factores y sus interacciones ejercen un efecto significativo sobre la variable de respuesta en un diseño factorial 2^k . Su propósito es comparar la variación explicada por el modelo con la variación no explicada (error experimental), estableciendo si los cambios observados en la respuesta pueden atribuirse al azar o a los tratamientos.

Formulación de hipótesis

Para cada efecto (principal o interacción) incluido en el modelo lineal, se plantean las siguientes hipótesis estadísticas:

$$\begin{cases} H_0 : \beta_j = 0, & \text{(el efecto del factor } j \text{ no es significativo)} \\ H_1 : \beta_j \neq 0, & \text{(el efecto del factor } j \text{ es significativo)} \end{cases}$$

Estas hipótesis se evalúan mediante el estadístico F , que compara la variación atribuida al efecto con la variación del error. Si $F_j > F_{\alpha, gl_j, gl_E}$, se rechaza la hipótesis nula y se concluye que el efecto es significativo.

Cálculo de los componentes del ANOVA

2.6.0.1. a) Suma total de cuadrados.

La variabilidad total de la respuesta se mide mediante la suma total de cuadrados:

$$SS_T = \sum_{i=1}^N (Y_i - \bar{Y})^2$$

donde Y_i es cada observación, $\bar{Y}$ la media general y N el número total de observaciones.

2.6.0.2. b) Descomposición de la variación.

En un diseño factorial 2^k , la variabilidad total se descompone como:

$$SS_T = SS_{\text{Factores}} + SS_{\text{Interacciones}} + SS_E$$

donde cada componente representa, respectivamente, la variación atribuida a los factores principales, a las interacciones y al error experimental.

2.6.0.3. c) Sumas de cuadrados individuales.

Cada efecto o interacción puede calcularse a partir de su contraste:

$$\text{Contraste}_j = \sum_{i=1}^N x_{ij} Y_i$$

donde x_{ij} son los coeficientes codificados (+1 o -1) del diseño. La suma de cuadrados para cada efecto se obtiene como:

$$SS_j = \frac{(\text{Contraste}_j)^2}{2^k n}$$

y la suma de cuadrados del error como:

$$SS_E = SS_T - \sum SS_j$$

donde n es el número de réplicas por combinación de tratamiento.

2.6.0.4. d) Grados de libertad y cuadrados medios.

Cada fuente de variación posee sus grados de libertad:

$$gl_T = N - 1, \quad gl_j = 1, \quad gl_E = N - p$$

Los cuadrados medios se calculan como:

$$MS_j = \frac{SS_j}{gl_j}, \quad MS_E = \frac{SS_E}{gl_E}$$

2.6.0.5. e) Estadístico de prueba.

El contraste de hipótesis se realiza mediante:

$$F_j = \frac{MS_j}{MS_E}$$

Si $F_j > F_{\alpha, gl_j, gl_E}$, se rechaza H_0 y se concluye que el efecto es significativo.

Cuadro general del ANOVA

Fuente	SS	gl	Estadístico F
A	SS_A	1	$F = \frac{MS_A}{MS_E}$
B	SS_B	1	$F = \frac{MS_B}{MS_E}$
C	SS_C	1	$F = \frac{MS_C}{MS_E}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$
AB	SS_{AB}	1	$F = \frac{MS_{AB}}{MS_E}$
AC	SS_{AC}	1	$F = \frac{MS_{AC}}{MS_E}$
AD	SS_{AD}	1	$F = \frac{MS_{AD}}{MS_E}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$
Error	SS_E	$N - 2^k$	—
Total	SS_T	$N - 1$	—

Cuadro 1. Estructura general del análisis de varianza (ANOVA) para un diseño 2^k . Cada efecto principal e interacción posee un grado de libertad. El número total de efectos es $2^k - 1$.

2.7. Diagrama de Pareto

Dado que se trata de un diseño factorial sin réplicas, no es posible estimar el error experimental debido a la falta de grados de libertad. Por esta razón, antes de realizar el análisis de varianza, se recurre al diagrama de Pareto con el fin de identificar los factores que tienen la mayor influencia en la respuesta estudiada.

En este caso, se utiliza el **método de Lenth (1989)**, que estima un error pseudo-estándar (*Pseudo Standard Error; PSE*) a partir de los efectos pequeños.

A continuación se detalla el procedimiento paso a paso:

1. Calcular los efectos factoriales.

Para cada factor o interacción:

$$e_j = \frac{1}{2^{k-1}} \sum_{i=1}^{2^k} x_{ij} y_i$$

donde $x_{ij} \in \{-1, +1\}$ representa el nivel del factor j en la corrida i , y y_i es la respuesta observada.

2. Obtener los valores absolutos de los efectos.

$$|e_j|$$

3. Calcular el estimador inicial s_0 .

$$s_0 = 1,5 \times \text{mediana}(|e_j|)$$

4. Identificar los efectos pequeños.

Se consideran efectos pequeños aquellos que cumplen:

$$|e_j| < 2,5 s_0$$

5. Calcular el error pseudo-estándar (PSE).

$$\text{PSE} = 1,5 \times \text{mediana}(|e_j| \text{ de los efectos pequeños})$$

6. Estandarizar los efectos.

$$t_j^* = \frac{|e_j|}{\text{PSE}}$$

7. Determinar la línea de significancia.

El software Minitab utiliza el margen de error (*Margin of Error; ME*) definido como:

$$\text{ME} = t_{1-\alpha/2, d} \times \text{PSE}$$

donde $d = n/3$ (siendo n el número de efectos considerados) y normalmente se toma $\alpha = 0,05$.

8. Construir el diagrama de Pareto.

- Ordenar los valores $|t_j^*|$ de mayor a menor.
- Representar cada uno como una barra en el gráfico.
- Dibujar una línea vertical en $t = \text{ME}/\text{PSE}$.
- Interpretación:
 - Barras que superan la línea $\rightarrow$ efectos significativos.
 - Barras menores $\rightarrow$ efectos probablemente nulos.

2.7.1. Resumen del procedimiento

Los efectos que superan la línea de significancia en el diagrama de Pareto se consideran **estadísticamente significativos**.

Etapa	Descripción	Fórmula
1	Calcular efectos e_j	$e_j = \frac{1}{2^{k-1}} \sum x_{ij} y_i$
2	Tomar valores absolutos	$ e_j $
3	Estimar s_0	$1,5 \times \text{median}(e_j)$
4	Filtrar efectos pequeños	$ e_j < 2,5 s_0$
5	Calcular PSE	$1,5 \times \text{median}(e_j _{\text{small}})$
6	Estandarizar	$ e_j /\text{PSE}$
7	Línea de Significancia	$t_{1-\alpha/2, n/3} \times \text{PSE}$
8	Graficar Pareto	Barras de $ t_j^* $ con ME

Cuadro 2. Etapas para la construcción del diagrama de Pareto de efectos en un diseño factorial 2^k

2.8. Puntos centrales

En los diseños factoriales 2^k , los puntos centrales son corridas experimentales realizadas en el nivel medio de todos los factores ($x_i = 0$). Su inclusión permite verificar la existencia de curvatura y estimar el error experimental puro.

Cuando se realizan n_c repeticiones en el punto central, se obtiene un conjunto de respuestas $y_{c1}, y_{c2}, \dots, y_{cn_c}$. El valor promedio en el punto central se calcula como:

$$\bar{y}_c = \frac{1}{n_c} \sum_{i=1}^{n_c} y_{ci}$$

Este promedio representa la respuesta experimental media en el centro del diseño. El modelo lineal ajustado con los puntos factoriales predice, para el punto central, una respuesta $\hat{y}_c = \beta_0$. Comparar ambos valores, $\bar{y}_c$ y $\hat{y}_c$, permite determinar si la relación entre los factores y la respuesta es lineal o si existe curvatura significativa.

Si $\bar{y}_c \approx \hat{y}_c$, el modelo de primer orden es adecuado. Si difieren significativamente, se concluye que existe curvatura y debe ajustarse un modelo de segundo orden, generalmente mediante un diseño compuesto central.

2.9. Superficie de respuesta

La Superficie de Respuesta es una técnica estadística empleada para modelar y analizar la relación entre una o más variables independientes (factores) y una variable dependiente o de respuesta. Su propósito principal es optimizar dicha respuesta, identificando las combinaciones de niveles de los factores que la maximizan o minimizan.

Esta metodología se basa en ajustar modelos de regresión que aproximan la forma de la superficie de respuesta dentro del espacio experimental. En términos generales, el modelo puede expresarse como:

$$y = f(x_1, x_2, \dots, x_k) + \varepsilon$$

donde:

- y es la respuesta observada,
- $x_1, x_2, \dots, x_k$ son las variables independientes o factores,
- $f(\cdot)$ es una función desconocida que relaciona los factores con la respuesta,
- ε representa el error aleatorio asociado.

En la práctica, la función $f(\cdot)$ se aproxima mediante modelos polinomiales, siendo los más comunes los modelos de primer y segundo orden.

2.9.1. Modelo de primer orden

El modelo lineal o de primer orden se utiliza cuando se asume que la relación entre los factores y la respuesta es aproximadamente lineal dentro del rango experimental. Se expresa como:

$$y = \beta_0 + \sum_{i=1}^k \beta_i x_i + \sum_{i < j} \beta_{ij} x_i x_j + \varepsilon$$

Este modelo permite estimar los efectos principales de los factores y las posibles interacciones entre ellos. La superficie resultante es un plano en el espacio de los factores.

2.9.2. Modelo de segundo orden

Cuando existe curvatura en la relación entre los factores y la respuesta, el modelo de primer orden no es suficiente. En tales casos, se utiliza un modelo cuadrático o de segundo orden, de la forma:

$$y = \beta_0 + \sum_{i=1}^k \beta_i x_i + \sum_{i < j} \beta_{ij} x_i x_j + \sum_{i=1}^k \beta_{ii} x_i^2 + \varepsilon$$

Este modelo incluye términos cuadráticos que permiten representar curvaturas y puntos de máximo o mínimo en la superficie de respuesta. La representación gráfica de este modelo produce una superficie curva o una forma paraboloide, dependiendo de los signos y magnitudes de los coeficientes.

2.10. Adición de puntos centrales

En los diseños factoriales 2^k , la estimación de los efectos se realiza considerando únicamente los niveles alto y bajo de cada factor, lo que permite ajustar un modelo lineal o de primer orden. Sin embargo, este modelo supone que la relación entre los factores y la respuesta es aproximadamente lineal dentro del rango experimental, lo cual puede no cumplirse en todos los casos.

Cuando se sospecha que la superficie de respuesta presenta curvatura, se incorporan puntos centrales al diseño experimental. Estos puntos corresponden a corridas realizadas en el nivel medio de todos los factores ($x_i = 0$) y se repiten varias veces con el fin de estimar el error experimental puro.

El promedio de las respuestas obtenidas en los puntos centrales, $\bar{y}_C$, se compara con el promedio de las respuestas en los puntos factoriales, $\bar{y}_F$. Si ambos valores son similares, se concluye que la superficie de respuesta es aproximadamente lineal. En cambio, si existe una diferencia significativa entre ellos, se infiere la presencia de curvatura cuadrática.

Esta comparación puede formalizarse mediante la suma de cuadrados de curvatura pura:

$$SS_{\text{curvatura pura}} = \frac{n_F n_C (\bar{y}_F - \bar{y}_C)^2}{n_F + n_C}$$

donde n_F es el número de puntos factoriales y n_C el número de puntos centrales. Esta medida permite evaluar la hipótesis:

$$H_0 : \sum_{j=1}^k \beta_{jj} = 0 \quad (\text{no hay curvatura})$$

$$H_1 : \sum_{j=1}^k \beta_{jj} \neq 0 \quad (\text{existe curvatura})$$

Si se detecta curvatura significativa, el modelo de primer orden resulta insuficiente y se recomienda ampliar el diseño mediante la incorporación de puntos axiales o la aplicación de diseños compuestos centrales (CCD). Estas extensiones permiten ajustar un modelo de segundo orden que describe con mayor precisión la superficie de respuesta, capturando tanto los efectos lineales e interactivos como los términos cuadráticos asociados a la curvatura.

3. METODOLOGÍA

3.1. METODOLOGÍA PARA EL DISEÑO EXPERIMENTAL

El diseño experimental seleccionado para abordar la problemática planteada corresponde a un 2^4 sin réplicas, en el cual los factores de tratamiento están representados por los diferentes químicos involucrados en el proceso.

3.1.1. Especificación de factores tratamiento

El experimento consideró como **factores tratamiento** los siguientes cuatro medios de cultivo: A (Glucosa), B (NH_4NO_3), C (FeSO_4) y D (MnSO_4).

Factor	U. originales		U. codificadas	
	Bajo	Alto	Bajo	Alto
A	20	60	-1	1
B	2	6	-1	1
C	6	30	-1	1
D	4	20	-1	1

Cuadro 3. Nivel especificado por factor

3.1.2. Diagrama de Pareto

Dado que se trata de un diseño factorial sin réplicas, no es posible estimar el error experimental debido a la falta de grados de libertad. Por esta razón, antes de realizar el análisis de varianza, se recurre al diagrama de Pareto con el fin de identificar los factores que tienen la mayor influencia en la respuesta estudiada.

En este caso, se emplea el **método de Lenth (1989)**, mediante el cual se obtuvo una línea de significancia (*Margin of Error, ME*) de **3.37**. Con esta referencia, se decidió mantener los factores principales *A*, *B*, *C* y *D*, así como las interacciones *AB* y *CD*. El resto de las interacciones se asignaron al error experimental con el fin de permitir su estimación. Los cálculos detallados pueden consultarse en el anexo titulado *CalculoPSE*.

3.1.3. Planteamiento de hipótesis

H_0 : No hay efecto significativo de glucosa, NH_4NO_3 , FeSO_4 , MnSO_4 ni sus interacciones sobre $(\text{CMC})^{-1}$ (Surfactina).

H_1 : Al menos un medio de cultivo tiene efecto significativo.

La hipótesis se contrastará dentro del marco del diseño experimental, evaluando el efecto de cada factor e interacción sobre la variable respuesta.

3.1.4. Validación de supuestos del modelo

El experimento contó con 16 observaciones. Los supuestos del modelo se verificaron de la siguiente manera:

- **Normalidad de residuos:** Se aplicó la prueba de normalidad mediante la gráfica de probabilidad normal.
- **Linealidad:** Evaluada a partir del gráfico de residuos frente a los valores ajustados, verificando la ausencia de patrones sistemáticos.
- **Homocedasticidad:** Inicialmente se evaluó de manera gráfica mediante la dispersión de los residuos frente a los valores ajustados. Luego, la verificación formal del supuesto se realizó con la prueba de Bartlett.
- **Independencia:** En este diseño factorial, los tratamientos están ordenados arbitrariamente. Cualquier patrón aparente sería producto del orden de la tabla, no de dependencia real entre errores.

3.1.5. Modelo propuesto

Se aplicó un análisis de varianza (ANOVA) para evaluar el efecto de los factores experimentales sobre la variable respuesta $(CMC)^{-1}$.

En este diseño, la **unidad experimental** corresponde a cada ejecución única del proceso de fermentación bajo condiciones específicas de medio de cultivo, sobre la cual se mide la **variable respuesta: surfactina**.

Definidos los factores y niveles, el modelo estadístico adoptado es el siguiente:

$$y_{ijkl} = \mu + A_i + B_j + C_k + D_l + (AB)_{ij} + (CD)_{kl} + \varepsilon_{ijkl}$$

donde:

- y_{ijkl} es la variable de respuesta $(CMC)^{-1}$ para la producción de surfactina
- μ es la media global de $(CMC)^{-1}$

Componentes del Modelo

Efectos Principales

- A_i : Efecto fijo de la **Glucosa** en el nivel i , con $i = 1, 2$ (20, 60 g/dm³)
- B_j : Efecto fijo del **NH₄NO₃** en el nivel j , con $j = 1, 2$ (2, 6 g/dm³)
- C_k : Efecto fijo del **FeSO₄** en el nivel k , con $k = 1, 2$ (6, 30×10^{-4} g/dm³)
- D_l : Efecto fijo del **MnSO₄** en el nivel l , con $l = 1, 2$ (4, 20×10^{-2} g/dm³)

Interacciones de 2 Términos

- $(AB)_{ij}$: Efecto de interacción entre **Glucosa y NH₄NO₃**
- $(CD)_{kl}$: Efecto de interacción entre **FeSO₄ y MnSO₄**

Error aleatorio

- ε_{ijkl} : Error aleatorio, donde $\varepsilon_{ijkl} \sim N(0, \sigma^2)$

3.1.6. Restricciones del Modelo

Tener en cuenta que para evitar sobreparametrización, se aplican las restricciones habituales:

$$\sum_i A_i = 0, \quad \sum_j B_j = 0, \quad \sum_k C_k = 0, \quad \sum_l D_l = 0$$

$$\sum_i (AB)_{ij} = 0 \quad \forall j, \quad \sum_j (AB)_{ij} = 0 \quad \forall i$$

$$\sum_k (CD)_{kl} = 0 \quad \forall l, \quad \sum_l (CD)_{kl} = 0 \quad \forall k$$

3.1.7. Optimización de la variable respuesta

Para la optimización de la producción de surfactina, se optó por una metodología secuencial de análisis gráfico que permitió caracterizar completamente la relación entre los factores del medio de cultivo y la variable respuesta $(CMC)^{-1}$.

Análisis Inicial mediante Gráficos de Efectos Principales e Interacciones

Inicialmente, se emplearon **gráficos de efectos principales** para visualizar la influencia individual de cada componente del medio (glucosa, NH₄NO₃, FeSO₄, MnSO₄) sobre la producción de surfactina. Estos gráficos permitieron identificar la magnitud y dirección de los efectos individuales, donde pendientes pronunciadas indicaron factores con mayor impacto en la respuesta.

Posteriormente, se utilizaron **gráficos de interacción** para evaluar cómo los factores trabajan en conjunto. La no paralelidad de las líneas en estos gráficos evidenció interacciones significativas, particularmente entre los pares glucosa-NH₄NO₃ y FeSO₄-MnSO₄.

Caracterización de la Región Óptima mediante Superficies de Respuesta

Una vez identificados los factores e interacciones significativas, se procedió a la caracterización detallada de la región óptima mediante **gráficos de superficie de respuesta**. Esta técnica permitió:

- Visualizar la relación funcional entre dos factores simultáneamente mientras se mantenían constantes los demás
- Identificar regiones de máxima respuesta dentro del espacio experimental definido
- Establecer la dirección de optimización para incrementar la producción de surfactina

La combinación de estas herramientas gráficas proporcionó una comprensión integral del sistema, facilitando la identificación de condiciones óptimas.

3.1.8. Puntos Centrales

El diseño factorial 2⁴ utilizado no contó con réplicas, por lo que se incorporaron seis puntos centrales en los niveles intermedios de los factores Glucosa, NH₄NO₃, FeSO₄ y MnSO₄, con el fin de estimar el error puro y evaluar la posible curvatura en la superficie de respuesta.

Factor	Unidades originales			Unidades codificadas		
	Bajo	Medio	Alto	Bajo	Medio	Alto
A	20	40	60	-1	0	+1
B	2	4	6	-1	0	+1
C	6	18	30	-1	0	+1
D	4	12	20	-1	0	+1

Cuadro 3. Niveles especificados por factor

A partir de los puntos factoriales y centrales se generó el

nuevo diseño experimental. Posteriormente, se verificaron los supuestos de normalidad, homocedasticidad e independencia de los residuos, habiéndose cumplido estos, se sabe que el modelo lineal de primer orden es adecuado para realizar el análisis de efectos y ANVA.

Se realizó el análisis de varianza considerando los efectos principales, las interacciones y el término de curvatura. Para la evaluación de la curvatura, se contrastaron las siguientes hipótesis:

H_0 : No existe curvatura (el modelo de primer orden es adecuado)

H_1 : Existe curvatura (se requiere un modelo de segundo orden)

Sin embargo, se observó una ligera curvatura en la superficie de respuesta. Esta curvatura indica que la relación entre los factores y la variable de respuesta no es completamente lineal dentro del rango experimental analizado. En consecuencia, aunque el modelo de primer orden permite identificar los efectos significativos y describir el comportamiento general del sistema, sería necesario incorporar términos cuadráticos para lograr una representación más precisa y capturar la curvatura observada.

3.2. Ajuste y validación del modelo

El modelo ajustado con puntos centrales presentó un error estándar reducido y un buen coeficiente de determinación, indicando una alta capacidad explicativa. El R^2 ajustado y el R^2 confirmó la estabilidad y capacidad predictiva del modelo en nuevos datos dentro del rango experimental.

3.3. Optimización

Una vez identificado el modelo con los factores y las interacciones significativas, se procedió a evaluar las condiciones de optimización del sistema. En este caso, el análisis se basó en la interpretación de las interacciones entre factores obtenidas del modelo con puntos centrales, ya que no fue posible construir superficies de respuesta al no incluir términos cuadráticos.

Debido a que los datos analizados provienen de un ejemplo experimental del texto de referencia y no de una recopilación propia, no fue posible añadir puntos axiales que permitieran extender el modelo hacia un diseño compuesto central (CCD) o de segundo orden. Por esta razón, la evaluación de las condiciones de optimización se realizó únicamente mediante la observación de las interacciones significativas y el análisis del sentido de los efectos principales en el modelo lineal.

De esta forma, las combinaciones de niveles de los factores que maximizan la respuesta se determinaron en función de la dirección de los efectos estimados, sin realizar una optimización gráfica basada en superficies de respuesta.


4. RESULTADOS

El experimento es de naturaleza factorial 2^4 . Los resultados se presentan en el cuadro 4. Se realizaron 16 corridas aleatorizadas. Cada combinación de los niveles de los factores fue repetida una sola vez. Asimismo, los factores son Glucosa (g/dm^3), NH_4NO_3 (g/dm^3), FeSO_4 ($\text{g/dm}^3 \times 10^{-4}$) y MnSO_4 ($\text{g/dm}^3 \times 10^{-2}$) y la variable y es la concentración de la surfactina CMC^{-1} la cual se mide indirectamente a través del cambio abrupto en la tensión superficial cuando se alcanza la concentración crítica micelar (CMC).

Run	Glucosa	NH_4NO_3	FeSO_4	MnSO_4	y
1	20.00	2.00	6.00	4.00	23
2	60.00	2.00	6.00	4.00	15
3	20.00	6.00	6.00	4.00	16
4	60.00	6.00	6.00	4.00	18
5	20.00	2.00	30.00	4.00	25
6	60.00	2.00	30.00	4.00	16
7	20.00	2.00	30.00	4.00	17
8	60.00	6.00	30.00	4.00	26
9	20.00	2.00	6.00	20.00	28
10	60.00	2.00	6.00	20.00	16
11	20.00	6.00	6.00	20.00	18
12	60.00	6.00	6.00	20.00	21
13	20.00	2.00	30.00	20.00	36
14	60.00	2.00	30.00	20.00	24
15	20.00	6.00	30.00	20.00	33
16	60.00	6.00	30.00	20.00	34

Cuadro 4. Resultados del experimento

En el análisis de un diseño factorial 2^4 realizado sin réplicas, no se puede aplicar un análisis de varianza clásico debido a la falta de replicaciones. En este contexto, se utiliza el diagrama de Pareto para identificar los efectos significativos de los factores y sus interacciones. Este gráfico recurre al PSE de Lenth, ya que establece un umbral crítico a partir del cual los efectos se consideran significativos. En este caso, el valor de PSE es 3.125; los términos cuyo efecto es mayor que este valor se etiquetan como relevantes. En el diagrama de Pareto mostrado en la Figura 1, se observa que los efectos más significativos están representados por las barras que superan el umbral de PSE = 3.125. Los efectos más prominentes incluyen a C (FeSO_4) siendo este el efecto más grande, con un valor de 3.374, indicando que C tiene una influencia predominante en la producción de surfactina, a A x B (Interacción entre Glucosa y NH_4NO_3) la cual también es significativa con un valor cercano al umbral crítico, lo que sugiere que sus efectos combinados juegan un papel importante, a D (MnSO_4) este factor también muestra una contribución considerable y a C x D (Interacción entre FeSO_4 y MnSO_4), la interacción entre estos dos factores se encuentra cerca del límite significativo, lo que implica que su combinación afecta la producción de surfactina. Los términos que no superan el umbral del PSE, como varias interacciones de tercer y cuarto orden, no son relevantes en el modelo y se consideran efectos no significativos.



PSE de Lenth = 3.125

Figura 1: Diagrama de Pareto

Aunque los efectos principales de Glucosa (factor A) y

NH_4NO_3 (factor B) no resultan significativo de manera individual, su interacción sí lo es. Bajo el principio de jerarquía del modelo, cuando una interacción es significativa se deben mantener en el modelo los efectos principales que la generan, aun cuando alguno de ellos no sea significativo de forma marginal. Esto se debe a que la significancia de Glucosa $\times NH_4NO_3$ indica que el efecto del NH_4NO_3 depende del nivel de la Glucosa y viceversa, por lo tanto, eliminar este factor produciría un modelo incoherente con la estructura de los datos.

4.1. Validación de supuestos del diseño

Se realizó una evaluación de los supuestos del modelo basado en el análisis de varianza de los efectos mas significativos (Ver Cuadro ??). Se comenzó con el supuesto de normalidad de los residuos. Para ello, se generó una gráfica de probabilidad normal, que se presenta en la Figura 2. La gráfica de probabilidad normal muestra una distribución bastante lineal de los residuos estandarizados, lo que indica que los residuos siguen una distribución normal. Además, se observa que los puntos están dispersos cerca de la línea teórica de normalidad, lo cual es una indicación de que los residuos no presentan sesgos importantes. Asimismo, en la prueba de normalidad de Anderson-Darling, se obtuvo un valor $p = 0,290$. Este valor p es mayor que el umbral común de significancia de 0.05, lo que implica que no hay evidencias para señalar que los residuos no provienen de una población normal. En general, se concluyó que el supuesto de normalidad se cumple adecuadamente.




Figura 2: Gráfica de probabilidad normal

Por otro lado, los puntos de la gráfica de residuos estandarizados en función de los valores ajustados $\hat{y}_i$, mostrada en la Figura 3 parecen estar distribuidos de forma aleatoria sin una tendencia evidente de dispersión creciente o decreciente. Los residuos se distribuyen alrededor de cero de manera casi homogénea, lo cual es una indicación de que el modelo cumple con el supuesto de homocedasticidad. Se observan un ligero patrón de aumento de la dispersión en función de los ajustados y una leve curvatura pero no son justificaciones suficientes para concluir que haya indicios de heterocedasticidad, por lo que el supuesto de homocedasticidad se cumple adecuadamente.




Figura 3: Ajustados vs residuos

En relación con el supuesto de independencia de los errores, se debe señalar que las 16 corridas del experimento fueron ejecutadas de manera aleatorizada en el laboratorio. Debido a esta aleatorización, la secuencia real de ejecución no coincide con el orden en que los datos se presentan en el cuadro de resultados, donde las corridas aparecen reordenadas según los niveles de los factores para facilitar su lectura. Esta reordenación impide construir una gráfica de residuales en función del orden de corrida o del tiempo, así como calcular e interpretar de manera válida el estadístico de Durbin-Watson, porque no se dispone del orden cronológico verdadero de las observaciones. Bajo este escenario, y siguiendo el principio de que la aleatorización rompe la posible correlación entre las mediciones sucesivas, se asume que las observaciones son independientes entre sí y que el modelo cumple razonablemente con el supuesto de independencia de los errores.

4.2. Análisis de varianza

Se muestra el análisis de varianza para evaluar los efectos de los factores y sus interacciones significativas identificadas en el diagrama de Pareto. La tabla ANOVA muestra que los factores Glucosa, $FeSO_4$, $MnSO_4$ y la interacción Glucosa $\times NH_4NO_3$, Glucosa $\times MnSO_4$ tienen efectos significativos en la producción de surfactina, ya que presentan valores de p menores a 0.05, sin embargo, el factor NH_4NO_3 no muestra un efecto significativo, ya que su valor p es de 1.00, lo que indica que no tiene un impacto relevante en la producción de surfactina dentro de este diseño experimental (Aún así su interacción con Glucosa es relevante en el modelo). Así, el análisis de varianza confirma que la interacción de Glucosa con NH_4NO_3 , Glucosa con $MnSO_4$ y los efectos individuales de $FeSO_4$ y $MnSO_4$ aparte del de Glucosa deben ser considerados en la optimización del proceso.

Fuente	gL	SC	MC	F	p
Glucosa	1	42.25	42.25	7.72	0.021
NH_4NO_3	1	0.00	0.00	0.00	1.00
$FeSO_4$	1	196.00	196.00	35.82	0.00
$MnSO_4$	1	182.25	182.25	33.00	0.00
Glucosa $\times NH_4NO_3$	1	196.00	196.00	35.82	0.000
$FeSO_4 \times MnSO_4$	1	64.00	64.00	11.70	0.008
Error	9	49.25	5.472		
Total	15	729.75			

Cuadro 5. Análisis de varianza

Asimismo el Cuadro 5 muestra la especificación del modelo

analizado:

Término	Coef.	IC 95 %	Valor p
Constante	22.875	(21.552 ; 24.198)	0.000
Glucosa	-1.625	(-2.948 ; -0.302)	0.021
NH_4NO_3	0.000	(-1.323 ; 1.323)	1.000
$FeSO_4$	3.500	(2.177 ; 4.823)	0.008
$MnSO_4$	3.375	(2.052 ; 4.698)	0.009
Glucosa $\times NH_4NO_3$	3.500	(2.177 ; 4.823)	0.008
$FeSO_4 \times MnSO_4$	2.000	(0.677 ; 3.323)	0.008

Cuadro 6. Resultados del experimento

El cuadro de métricas (Ver Cuadro ??) del diseño experimental presenta varios indicadores clave para evaluar el ajuste y la precisión del modelo. El valor de S es 2.33928, lo que representa la desviación estándar de los residuos, este valor bajo de S sugiere un buen ajuste del modelo a los datos. Asimismo, el R-cuadrado es de 93.25 %, lo que indica que el modelo explica el 93.25 % de la variabilidad total de los datos, el R-cuadrado ajustado es 88.75 %, este valor también es alto, lo que significa que el modelo sigue siendo adecuado incluso con la corrección por el número de variables. Por último el R-cuadrado predicho es de 78.67 %, este valor relativamente alto sugiere que el modelo tiene buena capacidad de predicción fuera de la muestra de entrenamiento. En conjunto, estas métricas indican que el modelo tiene un buen ajuste y una capacidad razonable para generalizar a nuevos datos.

Métrica	Valor
S	2.33928
R-cuadrado	93.25 %
R-cuadrado ajustado	88.75 %
R-cuadrado (pred.)	78.67 %

Cuadro 7. Métricas del diseño experimental

4.3. Condiciones de optimización

En la Figura 4, se presentan las interacciones que afectan la concentración de surfactina y (Las interacciones sombreadas no son significativas). Solo se consideran las interacciones significativas para la optimización del proceso, las cuales son Glucosa $\times NH_4NO_3$ y $FeSO_4 \times MnSO_4$. En la primera interacción significativa, Glucosa $\times NH_4NO_3$, se observa que el valor de y se maximiza cuando ambos factores se encuentran en sus niveles bajos, es decir, con Glucosa a 20 g/dm³ y NH_4NO_3 a 2 g/dm³. Este comportamiento sugiere que menores concentraciones de estos dos componentes favorecen la producción de surfactina en este caso específico. Por otro lado, en la segunda interacción significativa, $FeSO_4 \times MnSO_4$, el valor de y se maximiza cuando ambos factores se encuentran en sus niveles altos, es decir, $FeSO_4$ a 30×10^{-4} g/dm³ y $MnSO_4$ a 20×10^{-2} g/dm³. Este comportamiento indica que mayores concentraciones de estos componentes son necesarias para optimizar la producción de surfactina. Por lo tanto, la combinación óptima para maximizar la producción de surfactina es **20 g/dm³ para Glucosa, 2 g/dm³ para NH_4NO_3 , 30×10^{-6} g/dm³ para $FeSO_4$ y 20×10^{-2} g/dm³ para $MnSO_4$.**




Figura 4: Interacciones

En la Figura 5 se presenta la superficie de respuesta correspondiente a la interacción entre Glucosa y NH_4NO_3 , manteniendo constantes los niveles de $FeSO_4$ y $MnSO_4$. La superficie no muestra una forma plana sino un plano altamente torcido, lo cual confirma la presencia de interacción entre ambos factores. Se observa una tendencia ascendente de la respuesta $y = (CMC)^{-1}$ cuando tanto la Glucosa como el NH_4NO_3 se encuentran en sus niveles bajos, lo que indica que la combinación de concentraciones reducidas de ambos componentes favorece la producción de surfactina, confirmando los resultados de la gráfica de interacciones. En contraste, los valores más bajos de y se presentan cuando la Glucosa está en su nivel alto y el NH_4NO_3 en su nivel bajo, lo que evidencia que un exceso de fuente de carbono, acompañado de una baja disponibilidad de nitrógeno, reduce la eficiencia del proceso. De este modo, el punto de máxima respuesta se obtiene en las condiciones de Glucosa igual a 20 g/dm³ y NH_4NO_3 igual a 2 g/dm³, donde se logra la mayor producción relativa de surfactina.




Figura 5: Superficie de respuesta

En la Figura 6 se muestra la gráfica de contorno correspondiente a la interacción entre Glucosa y NH_4NO_3 , manteniendo constantes los niveles de $FeSO_4$ y $MnSO_4$. La región de color rojo más intenso representa el área donde se alcanza el valor máximo de la respuesta $y = (CMC)^{-1}$, confirmando lo observado previamente en la superficie de respuesta. Este máximo se presenta en las concentraciones bajas de ambos factores, es decir, en 20 g/dm³ de Glucosa y 2 g/dm³ de NH_4NO_3 , lo cual indica que niveles reducidos de carbono y nitrógeno favorecen la producción de surfactina. Asimismo, se observa que el valor más bajo de y ocurre en la combinación de Glucosa en su nivel alto (60 g/dm³) y NH_4NO_3 en su nivel bajo (2 g/dm³), lo

que sugiere que un exceso de Glucosa junto con una limitación de nitrógeno reduce la eficiencia de producción, confirmando el análisis de la superficie de respuesta. También se aprecia que la respuesta disminuye ligeramente en la condición inversa, es decir, Glucosa baja (20 g/dm³) y NH_4NO_3 alto (6 g/dm³), evidenciando un efecto combinado de ambos factores. Por otro lado, el nivel alto simultáneo de ambos factores (60 g/dm³ y 6 g/dm³) genera valores de y relativamente altos, aunque sin alcanzar la respuesta óptima.




Figura 6: Gráfica de Contorno

La Figura 7 muestra la superficie de respuesta correspondiente a la interacción entre $FeSO_4$ y $MnSO_4$, manteniendo constantes los niveles de Glucosa y NH_4NO_3 . A diferencia de la interacción entre Glucosa y NH_4NO_3 , esta superficie presenta una forma más plana, lo que indica que la interacción entre $FeSO_4$ y $MnSO_4$ tiene una significancia algo menor, como lo refleja su valor p de 0.008 frente al valor p de 0.000 de la interacción entre Glucosa y NH_4NO_3 . A pesar de esta diferencia en significancia, la interacción entre $FeSO_4$ y $MnSO_4$ sigue siendo importante, ya que el valor máximo de $y = (CMC)^{-1}$ se alcanza cuando ambos factores están en sus niveles más altos, es decir, $FeSO_4$ a 30×10^{-4} g/dm³ y $MnSO_4$ a 20×10^{-2} g/dm³. Por otro lado, el valor mínimo de y se presenta cuando ambos factores están en sus niveles bajos, es decir, $FeSO_4$ a 6×10^{-4} g/dm³ y $MnSO_4$ a 4×10^{-2} g/dm³. Los otros puntos de la superficie de respuesta se observan mejor en una gráfica de contorno. Esto confirma que la combinación óptima de $FeSO_4$ y $MnSO_4$ para maximizar la producción de surfactina se da en las concentraciones más altas de ambos factores, mientras que las concentraciones más bajas de estos dos componentes resultan en la menor producción de surfactina.




Figura 7: Superficie de respuesta

En la Figura 8 se evidencia con mayor claridad la simetría del diseño experimental en comparación con la superficie de respuesta. Se puede apreciar cómo la respuesta $y = (CMC)^{-1}$ aumenta hacia los niveles más altos de $FeSO_4$ y $MnSO_4$, lo que confirma que las concentraciones altas de estos dos componentes favorecen la producción de surfactina. El gradiente de la respuesta se hace más pronunciado en estas condiciones, con un aumento de la producción de surfactina a medida que ambos factores se incrementan. Además, se observa que, más allá del punto máximo (en los niveles más altos de $FeSO_4$ y $MnSO_4$) y el punto mínimo (en los niveles más bajos de ambos factores), los valores de y son similares en ciertos cruces. En particular, el cruce entre el nivel bajo de $FeSO_4$ y el nivel alto de $MnSO_4$, y el cruce entre el nivel alto de $FeSO_4$ y el nivel bajo de $MnSO_4$ presentan valores similares de y , que rondan entre 20 y 22.5 (muy cercanos al mínimo de y en esta interacción). Esto indica que, dentro de estos cruces, la concentración de surfactina no varía significativamente. En estos cruces, las concentraciones fijas de Glucosa (40 g/dm³) y NH_4NO_3 (4 g/dm³) siguen siendo factores determinantes en la respuesta observada.




Figura 8: Gráfica de Contorno

4.4. Puntos centrales

El diseño experimental 2^4 sin réplicas no permite una estimación directa del error a través de las réplicas, lo que dificulta la evaluación de la variabilidad del modelo. Para abordar esta limitación, se incorporan puntos centrales en el diseño. Estos permiten la estimación del error puro. Además, los puntos centrales ofrecen la ventaja adicional de permitir la evaluación de la curvatura en la función de respuesta, lo que resultó útil para identificar si el modelo de primer orden es adecuado o si es necesario ajustar un modelo de segundo orden. En la Figura 3 se evidenció ligera curvatura, por lo que se realiza el análisis respectivo.

Estos son los puntos centrales obtenidos en el experimento considerando los niveles intermedios de los factores:

Glucosa	NH_4NO_3	$FeSO_4$	$MnSO_4$	y
40	4	18	12	35
40	4	18	12	35
40	4	18	12	36
40	4	18	12	36
40	4	18	12	36
40	4	18	12	34

Cuadro 8. Puntos centrales agregados al diseño

4.5. Validación del diseño con puntos centrales

Se realizó la validación de los supuestos del nuevo modelo con los puntos centrales. En la Figura 9 los puntos se alinean de manera casi perfecta a lo largo de la línea recta, lo que sugiere que los residuos siguen una distribución normal. Además, como en el diseño anterior se llevó a cabo la prueba de normalidad de Anderson-Darling, este nuevo valor p es 0.427, siendo mayor que el umbral común de 0.05, lo que indica que no existe suficiente evidencia para concluir que los residuos no provienen de una distribución normal, validando la suposición de normalidad.




Figura 9: Probabilidad normal

La Figura 10 muestra que los residuos están distribuidos aleatoriamente alrededor de cero, lo que sugiere que no existe una tendencia sistemática clara en la dispersión de los residuos. Aunque se observan algunos patrones leves de curvatura en el gráfico, ya que algunos agrupamientos de los residuos podrían sugerir que el modelo no está capturando completamente la variabilidad de los datos, lo que podría ser indicativo de una posible no linealidad en la relación entre las variables regresoras y la variable $y = CMC^{-1}$.




Figura 10: Ajustados vs residuos

La prueba de White brinda un estadístico W de 21.098 inferior al valor crítico $\chi^2_{0.05, 14} = 23,685$, por lo que no hay evidencias significativas para rechazar homocedasticidad al 5 % de significancia, confirmando que se cumple el supuesto de homocedasticidad, además que utilizar el modelo lineal es estable en el ajuste de los datos.

Cuadro 1: Prueba de White

Estadístico	Valor
W	21.098

En el modelo ampliado con los seis puntos centrales tampoco se dispone del orden cronológico real ni de las 16 corridas factoriales ni de las repeticiones en el centro, ya que los datos se presentan reordenados por niveles de los factores. En consecuencia no es posible construir una gráfica de residuales versus orden de corrida ni aplicar de forma informativa el estadístico de Durbin-Watson como en el modelo anterior. Dado que tanto las corridas factoriales como los puntos centrales fueron ejecutados de manera aleatorizada, se adopta la suposición de que las observaciones son independientes entre sí.

4.6. Análisis de varianza con puntos centrales

El análisis de varianza con puntos centrales permite evaluar la significancia de los efectos y las interacciones entre los factores del modelo. En este caso, los efectos principales A (Glucosa), B (NH_4NO_3), C ($FeSO_4$) y D ($MnSO_4$) están presentes en el modelo, así como sus interacciones. Se observa que los efectos principales A, C y D son significativos con valores p menores a 0.05, mientras que el efecto B (NH_4NO_3) no es significativo, con un valor p de 1.00, lo que sugiere que la concentración de NH_4NO_3 no tiene un impacto importante en la respuesta. En cuanto a las interacciones, se encuentra que las interacciones A x B, A x D, B x C y C x D son todas significativas, con valores p menores a 0.05, lo que indica que la combinación de estos factores tiene un efecto considerable sobre la variable respuesta. La interacción A x C tiene un valor p mayor a 0.05 (0.241), por lo que no se considera significativa y se puede excluir del modelo. Finalmente, el valor de la curvatura tiene un valor p de 0.000, lo que indica que podría ser necesario considerar un modelo que incluya términos cuadráticos del tipo x_i^2 para capturar mejor las variaciones no lineales en la respuesta. En resumen, los efectos significativos a considerar en el análisis posterior son A (Glucosa), C ($FeSO_4$), D ($MnSO_4$), A x B, A x D, B x C y C x D. Las interacciones no significativas, como A x C y B x D, pueden ser eliminadas del modelo para simplificar la interpretación. Asimismo, para respetar el principio de jerarquía, aunque el efecto B no es significativo, su interacción B x C si lo es, por lo que el efecto B también es considerado dentro del análisis de varianza de los efectos mas significativos.

Fuente	gL	SC	MC	F	p	Fuente	gL	SC	MC	F	p
A (Glucosa)	1	42.25	42.25	74.56	0.000	A (Glucosa)	1	425.21	425.21	25.89	0.000
B NH_4NO_3	1	0.00	0.000	0.00	1.000	B NH_4NO_3	1	0.00	0.00	0.00	1.000
C $FeSO_4$	1	196.00	196.00	345.88	0.000	C $FeSO_4$	1	196.00	196.00	120.10	0.000
D $MnSO_4$	1	182.25	182.25	321.62	0.000	D $MnSO_4$	1	182.25	182.25	111.68	0.000
A $\times$ B	1	196.00	196.000	345.88	0.000	A $\times$ B	1	196.00	196.00	120.10	0.000
A $\times$ C	1	1.00	1.00	1.76	0.241	A $\times$ D	1	12.25	12.25	7.51	0.018
A $\times$ D	1	12.25	12.25.250	21.62	0.006	B $\times$ C	1	20.25	20.25	12.41	0.004
B $\times$ C	1	20.25	20.25	35.74	0.002	C $\times$ D	1	64.00	64.00	39.22	0.000
B $\times$ D	1	1.00	1.00	1.76	0.241	Curvatura	1	659.28	659.28	403.98	0.000
C $\times$ D	1	64.00	64.00	112.94	0.000	Falta de ajuste	7	16.75	2.393	4.22	0.066
A $\times$ B $\times$ C	1	2.25	2.25	3.97	0.103	Error puro	5	2.83	0.567		
A $\times$ B $\times$ D	1	0.00	0.00	0.00	1.000	Total	21	1391.86			
A $\times$ C $\times$ D	1	4.00	4.00	7.06	0.045						
B $\times$ C $\times$ D	1	2.25	2.25	3.97	0.103						
A $\times$ B $\times$ C $\times$ D	1	6.25	6.25	11.03	0.021						
Curvatura	1	659.28	659.28	1163.44	0.000						
Error puro	5	2.83	0.567								
Total	21	1391.86									

Cuadro 9. Análisis de varianza con puntos centrales

El análisis de varianza presentado en el para el Cuadro ?? del modelo que incluye únicamente los efectos más significativos confirma que los factores Glucosa, $FeSO_4$ y $MnSO_4$ ejercen un efecto estadísticamente significativo sobre la respuesta, con valores p iguales a 0.000 en todos los casos. El factor NH_4NO_3 mantiene un valor p de 1.000, lo que indica que su efecto principal no es significativo de manera aislada; sin embargo, se mantiene en el modelo debido a que participa en una interacción significativa con la Glucosa. Las interacciones Glucosa $\times$ NH_4NO_3 y $FeSO_4 \times MnSO_4$ también resultan altamente significativas como en el modelo general, lo que implica que la combinación simultánea de estos factores modifica la respuesta de forma más marcada que los factores actuando por separado. Asimismo, la interacción Glucosa $\times$ $MnSO_4$ y la interacción $NH_4NO_3 \times FeSO_4$ presentan valores p de 0.018 y 0.004 respectivamente, por lo que también deben ser consideradas en la interpretación del comportamiento del proceso. Un aspecto importante de este anova es que el término de curvatura presenta un valor p igual a 0.000, lo que indica evidencia clara de que la relación entre los factores estudiados y la respuesta no es estrictamente lineal. En otras palabras, aun cuando el modelo cumple adecuadamente los supuestos de normalidad y varianza constante, la presencia de un efecto de curvatura significativo confirma que la superficie de respuesta presenta una forma no plana. La falta de ajuste tiene un valor p de 0.066, por encima del nivel de significancia habitual de 0.05, por lo que no hay evidencia suficiente para concluir que el modelo es inadecuado. El error puro es pequeño, lo que indica una buena repetibilidad de las corridas en el punto central.

Cuadro 10. Análisis de varianza de efectos más significativos y puntos centrales

Asimismo, la especificación del nuevo modelo con puntos centrales se muestra en el Cuadro 11:

Término	Coef.	IC 95 %	Valor p
Constante	22.875	(22.179 ; 23.571)	0.000
Glucosa	-1.625	(-2.321 ; -0.929)	0.000
NH_4NO_3	0.000	(-0.696 ; 0.696)	1.000
$FeSO_4$	3.500	(2.804 ; 4.196)	0.000
$MnSO_4$	3.375	(2.679 ; 4.071)	0.000
Glucosa $\times$ NH_4NO_3	3.500	(2.804 ; 4.196)	0.000
Glucosa $\times$ $MnSO_4$	-0.875	(-1.571 ; -0.179)	0.018
$NH_4NO_3 \times FeSO_4$	1.125	(0.429 ; 1.821)	0.002
$FeSO_4 \times MnSO_4$	2.000	(1.304 ; 2.696)	0.000
Punto central	12.292	(10.959 ; 13.624)	0.000

Cuadro 11. Especificación del nuevo modelo

Las métricas de ajuste este modelo (Ver Cuadro ??) muestran que el estadístico S es igual a 1.27748, lo que indica que el error estándar de los residuos es bajo en comparación con el rango de la respuesta, por lo que las predicciones del modelo son precisas alrededor de los valores observados. El coeficiente de determinación R-cuadrado es 98.59 %, lo que significa que el modelo explica casi toda la variabilidad de la respuesta experimental cuando se consideran los efectos principales seleccionados, las interacciones significativas y el término de curvatura. El R-cuadrado ajustado toma el valor de 97.54 %, valor muy cercano al R-cuadrado, lo que indica que la inclusión de los términos en el modelo está justificada y que no se está sobreajustando con efectos irrelevantes. Finalmente, el R-cuadrado predicho es 93.42 %, lo que confirma que el modelo mantiene una capacidad adecuada de predicción para nuevas observaciones dentro de la región experimental estudiada. La proximidad entre el R-cuadrado, el R-cuadrado ajustado y el R-cuadrado predicho respalda que el modelo es estable, parsimonioso y apropiado para describir el efecto conjunto de los factores sobre la producción de surfactina.

Métrica	Valor
S	1.27748
R-cuadrado	98.59 %
R-cuadrado ajustado	97.54 %
R-cuadrado (pred.)	93.42 %

Cuadro 12. Métricas del diseño experimental

Si se comparan estas métricas con las obtenidas en el modelo inicial ajustado al diseño factorial 2^4 sin puntos centrales, se observa una mejora clara en la calidad del ajuste. En el modelo sin puntos centrales el estadístico S fue 2.33928, el R-cuadrado alcanzó 93.25 %, el R-cuadrado ajustado 88.75 % y el R-cuadrado de predicción 78.67 %. Estos valores indican que el primer modelo explicaba una proporción importante de la variabilidad, pero dejaba una fracción no despreciable sin explicar y mostraba una capacidad predictiva más limitada. Al incorporar los puntos centrales y reestimar el modelo con los efectos más significativos, el error estándar de los residuos se redujo de 2.33928 a 1.27748, lo que refleja una disminución importante en la dispersión de los errores. De forma consistente, el R-cuadrado aumentó de 93.25 % a 98.59 %, lo que significa que el nuevo modelo captura una porción mucho mayor de la variabilidad total. El R-cuadrado ajustado pasó de 88.75 % a 97.54 %, indicando que el modelo ampliado sigue siendo parsimonioso y que los términos añadidos (interacciones y curvatura) fueron realmente necesarios. Finalmente, el R-cuadrado de predicción mejoró de 78.67 % a 93.42 %, lo que muestra que el modelo con puntos centrales no solo describe mejor los datos observados, sino que también generaliza mejor dentro de la región experimental. Esta comparación justifica el uso de puntos centrales y la incorporación explícita de la curvatura en el análisis.

4.7. Condiciones de optimización con puntos centrales

En las condiciones de optimización obtenidas a partir del diseño factorial 2^4 complementado con puntos centrales (Ver Figura 11) se observó que, para la interacción entre Glucosa y NH_4NO_3 , la respuesta $y = (\text{CMC})^{-1}$ se maximiza cuando ambos factores se encuentran en sus niveles bajos, es decir, 20 g/dm³ para Glucosa y 2 g/dm³ para NH_4NO_3 . De manera similar, en la interacción Glucosa $\times$ MnSO_4 la respuesta máxima se alcanza con 20 g/dm³ de Glucosa y 20×10^{-2} g/dm³ de MnSO_4 . En la interacción $\text{NH}_4\text{NO}_3 \times \text{FeSO}_4$, el valor máximo de la respuesta se obtiene con 6 g/dm³ de NH_4NO_3 y 30×10^{-6} g/dm³ de FeSO_4 . Finalmente, en la interacción $\text{FeSO}_4 \times \text{MnSO}_4$ la respuesta se maximiza con 30×10^{-6} g/dm³ de FeSO_4 y 20×10^{-2} g/dm³ de MnSO_4 . Al integrar estas condiciones de optimización para todas las interacciones significativas se obtiene que las condiciones globales que maximizan la respuesta son **20 g/dm³ para Glucosa, 2 g/dm³ para NH_4NO_3 , 30×10^{-6} g/dm³ para FeSO_4 y 20×10^{-2} g/dm³ para MnSO_4** . Es importante señalar que estas condiciones coinciden con las obtenidas previamente en el análisis del diseño factorial 2^4 sin puntos centrales, lo cual confirma la consistencia del efecto de los factores más influyentes.

Sin embargo, la prueba de curvatura resultó significativa, lo que indica que el modelo lineal de primer orden no es completamente adecuado para describir el comportamiento de la respuesta en toda la región experimental. Esto sugiere la necesidad de ajustar un modelo polinómico de segundo orden que permita capturar con mayor precisión la variabilidad asociada a la curvatura. No obstante, al intentar incorporar términos cuadráticos de la forma x_i^2 en un diseño codificado en niveles +1 y -1 como el 2^4 , pueden surgir problemas de colinealidad y pérdida de ortogonalidad en la matriz de diseño, lo que dificulta la estimación estable de los coeficientes y limita la validez del análisis de varianza para el modelo extendido. Por esta razón, para una caracterización más robusta de la superficie de respuesta y para estimar sin problemas de colinealidad los términos de segundo orden, se recomienda ejecutar un diseño de superficie de respuesta propiamente dicho, como un diseño central compues-

to (CCD) o un diseño Box-Behnken. Esta necesidad de un diseño adicional constituye la principal limitación metodológica del presente estudio.




Figura 11: Interacciones

5. CONCLUSIONES

- La combinación óptima de factores que maximiza la producción de surfactina, expresada como la inversa de la concentración micelar crítica $(\text{CMC})^{-1}$, se alcanzó con niveles bajos de Glucosa y NH_4NO_3 y niveles altos de FeSO_4 y MnSO_4 . Específicamente, las condiciones óptimas estimadas fueron 20 g/dm³ de Glucosa, 2 g/dm³ de NH_4NO_3 , 30×10^{-6} g/dm³ de FeSO_4 y 20×10^{-2} g/dm³ de MnSO_4 . Estas condiciones corresponden a la región de máxima respuesta identificada tanto en el diseño factorial 2^4 inicial como en el modelo con puntos centrales, confirmando la consistencia de los efectos de los factores más influyentes sobre la producción de surfactina.
- El análisis de varianza y el diagrama de Pareto mostraron que existen efectos principales e interacciones significativas que influyen de manera directa en la producción de surfactina. Los factores FeSO_4 y MnSO_4 presentaron los mayores efectos principales sobre la respuesta, seguidos por la glucosa, mientras que el NH_4NO_3 no fue significativo de forma marginal pero se mantuvo en el modelo por su participación en interacciones de orden superior. Las interacciones Glucosa $\times$ NH_4NO_3 y $\text{FeSO}_4 \times \text{MnSO}_4$ resultaron estadísticamente significativas, evidenciando que la respuesta no depende únicamente de los factores de manera aislada sino también de su combinación. Por lo tanto, se confirma que tanto los efectos principales como las interacciones entre los nutrientes del medio de cultivo condicionan la magnitud de la producción de surfactina.
- La cuantificación de la contribución porcentual de los factores a la variabilidad total mostró que en el modelo factorial 2^4 sin puntos centrales los factores FeSO_4 y MnSO_4 explicaron la mayor proporción de la variación en la respuesta, con aportes cercanos al 25 % cada uno, mientras que la glucosa presentó una contribución menor pero aún relevante y el NH_4NO_3 no explicó variación de forma individual. Al incorporar los puntos centrales y ajustar el modelo con los efectos más significativos, estas contribuciones se mantuvieron en el mismo orden de importancia, confirmando que FeSO_4 y MnSO_4 son los factores de mayor peso en el sistema, seguidos por la glucosa y por las interacciones Glucosa $\times$ NH_4NO_3 y $\text{FeSO}_4 \times \text{MnSO}_4$. La consistencia de estas

contribuciones en ambos modelos indica que la estructura de efectos del proceso es estable y que la variabilidad de la producción de surfactina está dominada por las fuentes de hierro y manganeso del medio de cultivo.

- A partir de los resultados obtenidos se recomienda, para la optimización de la producción de surfactina, operar el medio de cultivo con concentraciones bajas de glucosa y NH_4NO_3 y con concentraciones altas de FeSO_4 y MnSO_4 , dado que esta combinación condujo de manera consistente a los mayores valores de $(\text{CMC})^{-1}$ en ambos modelos evaluados. Asimismo, debido a que la prueba de curvatura resultó significativa, se concluye que el modelo lineal de primer orden no describe completamente el comportamiento del proceso y que, por tanto, las estrategias de optimización deben considerar modelos polinómicos de segundo orden que incorporen términos cuadráticos del tipo x_i^2 para capturar la forma real de la superficie de respuesta. Sin embargo, dado que el diseño factorial 2^4 con puntos centrales presenta limitaciones para estimar de forma estable dichos términos por posibles problemas de colinealidad, se recomienda la ejecución de un diseño de superficie de respuesta, como un diseño central compuesto o un Box-Behnken, que permita refinar las condiciones óptimas identificadas y generar un modelo predictivo adecuado para el escalamiento del proceso.

6. BIBLIOGRAFÍA

1. Montgomery, D. C. (2017). *Design and Analysis of Experiments* (9th ed.). John Wiley & Sons.
2. Hoshmand, A. R. (2006). *Design of Experiments for Agriculture and the Natural Sciences* (2nd ed.). CRC Press, Taylor & Francis Group.
3. Box, G. E. P., Hunter, J. S., & Hunter, W. G. (2005). *Statistics for Experimenters: Design, Innovation, and Discovery* (2nd ed.). Wiley-Interscience.
4. *Journal of Chemical Technology and Biotechnology*. (1997). Response Surface Optimization of the Critical Media Components for the Production of Surfactin, 68(3), 263-270.

7. ANEXOS

7.1. Anexo A: Data_Surfactinase.xlsx

En este archivo encontrará los datos del diseño factorial, además de sus 6 puntos centrales añadidos, así como la descripción explícita de cada una de las variables del estudio.

7.2. Anexo B: Data_Optimizacion.mpx

En este archivo encontrará el minitab con el paso a paso del cálculo del ANOVA, pareto y optimización en el diseño factorial completo. De igual manera está el desarrollo del diseño luego de agregar los 6 puntos centrales.

7.3. Anexo C: CalculoPSE.xlsx

En este archivo encontrará los cálculos realizados para obtener el PSEUSO ERROR ESTÁNDAR para graficar el diagrama de pareto.

7.4. Anexo D: Prueba_de_White.R

En este archivo encuentra la Prueba de White realizada para probar homocedasticidad cuando se incluyen las observaciones con puntos centrales.